

Material Suplementar:

Revisão de Arquiteturas de Redes Neurais

Pedro Calligaris Delbem

Este documento serve como material de apoio ao Trabalho de Conclusão de Curso (TCC) “Redes neurais celulares implementada em um computador quântico - NISQ”.

1 Contexto: Paradigmas de Arquiteturas de Redes Neurais

Para compreender a relevância e a particularidade das CelNN no contexto do TCC, é útil revisitar a evolução das arquiteturas de redes neurais artificiais. Cada novo modelo surgiu para superar as limitações de seus predecessores, seguindo uma trajetória de crescente complexidade e capacidade de abstração.

1.1 Perceptron

Proposto por Frank Rosenblatt em 1958 (1), o Perceptron é o modelo mais fundamental de um neurônio artificial. Ele consiste em uma única camada que recebe entradas, as pondera com pesos sinápticos e aplica uma função de ativação (geralmente uma função degrau) para produzir uma saída binária. Seu funcionamento se baseia em aprender a ajustar esses pesos para classificar dados.

No entanto, sua grande limitação, demonstrada por Minsky e Papert em 1969 (2), é a incapacidade de resolver problemas que não são linearmente separáveis, como a simples operação lógica **XOR**¹.

1.2 Redes Neurais Multicamadas (MLP)

Para superar a limitação do Perceptron, surgiram as Redes Neurais Multicamadas, ou *Multi-Layer Perceptrons* (MLP). A inovação fundamental foi a introdução de uma ou mais camadas ocultas (*hidden layers*) entre a camada de entrada e a de saída. Ao utilizar funções de ativação não-lineares, as MLP se tornaram capazes de aprender representações complexas e não-lineares dos dados, resolvendo problemas como o XOR. A arquitetura MLP é caracterizada pela conectividade total (*fully-connected*).

¹Durante a iniciação científica que fundamentou este trabalho, foi desenvolvido um Perceptron Quântico adaptado do circuito proposto em (3). Curiosamente, a análise revelou uma limitação oposta à do modelo clássico: o Perceptron Quântico demonstrou ser capaz de resolver *apenas* problemas linearmente não-separáveis, como o XOR, falhando em tarefas de separação linear. O código e a análise detalhada destes resultados estão disponíveis no repositório do autor: <https://github.com/delbempedro/ic/>.

1.3 Deep Learning (Aprendizagem Profunda)

O conceito de *Deep Learning* (ou Aprendizagem Profunda) é caracterizado pelo uso de arquiteturas com um número muito grande de camadas ocultas (redes “profundas”). Com o avanço do poder computacional (principalmente com o uso de GPU) e a disponibilidade de enormes volumes de dados (*big data*), modelos profundos tornaram-se extremamente relevantes. A profundidade da rede permite que ela aprenda uma hierarquia de características, desde as mais simples nas primeiras camadas até as mais abstratas e complexas nas camadas finais.

1.4 Inteligência Artificial Generativa

Mais recentemente, um novo paradigma emergiu com foco não em classificar, mas em **gerar** novos dados: a **Inteligência Artificial Generativa**. Este paradigma utiliza arquiteturas projetadas para aprender a distribuição de probabilidade subjacente aos dados de treinamento, que se tornaram a base para os LLM, capazes de criar textos, imagens e outros conteúdos com uma fidelidade sem precedentes.

1.5 Conclusão: O Contraste com a CelNN

É neste contexto de redes com conectividade global, alta dependência de dados e, agora, capacidades generativas, que as CelNN se destacam como um paradigma distinto. Em vez de aumentar a profundidade ou a complexidade para gerar conteúdo, elas se baseiam em uma filosofia de **interação local e dinâmica temporal contínua**, oferecendo uma abordagem computacional fundamentalmente diferente e alinhada com a simulação de sistemas físicos complexos, foco principal do TCC.

REFERÊNCIAS

- 1 F. Rosenblatt. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6):386–408, 1958.
- 2 Marvin Minsky and Seymour Papert. *Perceptrons: An Introduction to Computational Geometry*. MIT Press, 1969.
- 3 Michele Grossi et al. A survey of quantum computing for finance. *IEEE Transactions on Quantum Engineering*, 3:1–34, 2021.